

Penyesuaian YOLOv8n untuk Deteksi Presisi Komedo Hitam, Jerawat Jamur, dan Jerawat Nodul

Tugas Akhir

diajukan untuk memenuhi salah satu syarat

memperoleh gelar sarjana

pada Program Studi Informatika

Fakultas Informatika Universitas Telkom

1301213527

Raditha Ariyani



Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2025

LEMBAR PENGESAHAN

Penyesuaian YOLOv8n untuk Deteksi Presisi Komedo Hitam, Jerawat Jamur, dan Jerawat Nodul

Fine-Tuning YOLOv8n for Precision Detection of Blackhead, Fungal Acne, and Acne Nodule

NIM : 1301213527

Raditha Ariyani

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagian syarat memperoleh gelar pada Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung, 23 Juli 2025

Menyetujui

Pembimbing I,

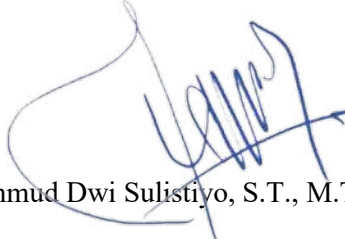


Dr. Putu Harry Gunawan, S.Si., M.Si., M.Sc

NIP: 16860043

Ketua Program Studi

Sarjana Informatika,



Mahmud Dwi Sulistiyo, S.T., M.T., Ph.D.

NIP: 13880017

LEMBAR PERNYATAAN

Dengan ini saya, Raditha Ariyani, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Penyesuaian YOLOv8n untuk Deteksi Presisi Komedo Hitam, Jerawat Jamur, dan Jerawat Nodul beserta dengan seluruh isinya adalah merupakan hasil karya sendiri, dan saya tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dalam masyarakat keilmuan, serta produk dari tugas akhir bukan merupakan produk dari *Generative AI*. Saya siap menanggung resiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan TA atau jika ada klaim dari pihak lain terhadap keaslian karya,

Bandung, 23 Juli 2025

Yang Menyatakan



Raditha Ariyani

1301213527

Penyesuaian YOLOv8n untuk Deteksi Presisi Komedo Hitam, Jerawat Jamur, dan Jerawat Nodul

Raditha Ariyani¹, Putu Harry Gunawan², Narita Aquarini³, Ida Ayu Manik Partha Sutema⁴, Keri Lestari⁵

^{1,2}Fakultas Informatika, Universitas Telkom, Bandung

³École Doctorale Science Economics, Université de Poitiers Intervenant
Finance, La Rochelle

⁴Fakultas Sains, Universitas Bali Internasional, Bali

⁵Fakultas Farmasi, Universitas Padjadjaran, Bandung

¹astxyz@students.telkomuniversity.ac.id, ²phgunawan@telkomuniversity.ac.id,

³aquarinin@excelia-group.com, ⁴manikparthasutema@unbi.ac.id,

⁵lestarikd@unpad.ac.id

Abstrak

Analisis visual untuk membedakan secara akurat subtype jerawat seperti komedo hitam (*blackhead*), jerawat fungal, dan jerawat nodul menghadapi kendala signifikan akibat karakteristik lesi yang subtil dan tumpang tindih. Padahal, diferensiasi ini bersifat esensial untuk efektivitas penanganan dermatologis. Untuk mengatasi tantangan tersebut, penelitian ini melakukan penyesuaian secara teliti terhadap model deteksi objek YOLOv8n guna meningkatkan presisi deteksi. Studi ini memanfaatkan sebuah dataset terkurasi berisi 2008 citra dari sumber publik (Skin-90, DermNet), yang dianotasi secara manual di bawah awasan seorang ahli. Melalui proses *fine-tuning* iteratif yang mengeksplorasi berbagai hyperparameter kunci, konfigurasi model yang paling optimal dievaluasi menggunakan metrik *Precision*, *Recall*, dan mAP50. Hasilnya menunjukkan pencapaian presisi keseluruhan tertinggi sebesar 0.693 dan mAP50 keseluruhan yang solid sebesar 0.589. Adapun skor mAP50 untuk setiap kelas adalah 0.750 untuk jerawat jamur, 0.576 untuk jerawat nodul, dan 0.442 untuk komedo hitam. Validasi kualitatif mendukung kapabilitas model dalam melokalisasi lesi secara akurat, kendati masih terdapat beberapa *false positive* pada kelas komedo hitam. Penelitian ini membuktikan bahwa optimisasi sistematis pada model YOLOv8n dapat menghasilkan kemampuan diferensiasi presisi tinggi untuk subtype jerawat yang kompleks, sekaligus menjadi landasan prospektif bagi pengembangan instrumen diagnostik dermatologis berbantuan komputer yang reliabel.

Kata kunci: deteksi jerawat, YOLOv8n, *fine-tuning*, deteksi presisi

1. Pendahuluan

Penampilan pribadi merupakan aspek penting untuk diperhatikan karena secara signifikan memengaruhi karakter individu. Penampilan yang kurang memuaskan, seperti yang disebabkan oleh jerawat, dapat menurunkan kepercayaan diri, menyebabkan kecemasan, bahkan depresi. Jerawat (*acne vulgaris*) adalah penyakit kulit yang umum terjadi, terutama pada remaja, yang diakibatkan oleh peradangan pada folikel pilosebacea (folikel rambut) dan kelenjar sebacea (kelenjar penghasil minyak) [1], [2]. Jerawat terbagi menjadi dua jenis: lesi inflamasi, seperti papula, pustula, nodul, dan kista; serta lesi non-inflamasi, seperti komedo (baik komedo terbuka maupun tertutup) [3]. Jerawat memengaruhi sekitar 85% populasi manusia berusia 11-30 tahun dan umumnya muncul di wajah, punggung, dada, dan area bahu, yang merupakan area dengan konsentrasi kelenjar sebacea yang tinggi [4], [5], [6]. Meskipun jerawat sering kali dianggap sebagai masalah kosmetik semata, kondisi ini memiliki dampak yang cukup besar terhadap penampilan fisik pada remaja, memengaruhi kualitas hidup mereka secara keseluruhan, baik dalam hubungan sosial maupun kesejahteraan emosional, menjadikannya isu yang jauh lebih kompleks daripada sekadar kelainan kulit [7], [8].

Untuk pengobatan yang efektif, dokter kulit (dermatolog) harus mengidentifikasi dan memahami secara akurat jenis jerawat spesifik yang dialami pasien. Namun, karena keterbatasan waktu yang sering kali tersedia untuk konsultasi, pemeriksaan kulit secara manual dapat menjadi tantangan dan memakan waktu [4]. Salah satu pendekatan yang menjanjikan untuk mengatasi masalah ini adalah dengan memanfaatkan teknologi kecerdasan buatan (AI), khususnya model deteksi objek berbasis *deep learning*.

Deep learning, sebuah sub-bidang dari *machine learning*, telah banyak diadopsi untuk menganalisis citra kulit, termasuk jerawat, karena kemampuannya dalam mendeteksi pola dan fitur halus pada citra wajah atau kulit yang mungkin sulit dilihat oleh mata manusia [1], [2], [4], [5]. Penerapan *deep learning* dalam deteksi jerawat memfasilitasi diagnosis yang lebih cepat dan berpotensi lebih akurat. Dengan kemampuan untuk memproses gambar secara otomatis dan mengenali berbagai jenis jerawat, teknologi ini dapat membantu dokter kulit dalam memilih perawatan yang tepat dan menyediakan solusi diagnostik yang lebih efisien.

Beberapa penelitian telah mengeksplorasi penggunaan model deteksi objek untuk deteksi jerawat. Penelitian awal yang menggunakan YOLOv5 menunjukkan potensi yang menjanjikan, sebagaimana dibuktikan oleh penelitian yang melaporkan akurasi yang baik [9]. Namun, penelitian lain yang menggunakan YOLOv5 untuk deteksi multikelas, seperti yang dilakukan oleh Sangha dan Rizvi, melaporkan skor mAP@0.5 sekitar 26.50% [1]. Angka-angka ini mengindikasikan adanya ruang yang signifikan untuk perbaikan, terutama dalam membedakan antara berbagai jenis lesi jerawat dengan fidelitas tinggi.

Kemajuan terkini dalam arsitektur YOLO, seperti YOLOv8, telah meningkatkan kinerja deteksi objek baik dari segi kecepatan maupun akurasi [10], [11]. Sistem ACNE8M, yang menggunakan model berbasis YOLOv8, mencapai hasil yang signifikan dengan skor *mean Average Precision* (mAP) sebesar 0.69 dan akurasi 0.976 untuk mendeteksi dan membedakan berbagai jenis jerawat serta kondisi terkait [12]. Meskipun hasil ini menyoroti kekuatan YOLOv8 dan potensinya untuk deteksi jerawat yang komprehensif, mencapai diferensiasi visual otomatis yang sangat presisi untuk jenis jerawat tertentu hanya dari gambar tetap menjadi tantangan besar. Walaupun kondisi seperti jerawat jamur (*fungus acne*), nodul, dan komedo hitam (*blackhead*) secara medis berbeda, manifestasinya dalam gambar dapat menunjukkan karakteristik visual yang halus atau tumpang tindih, yang menantang bahkan model deteksi objek canggih sekalipun untuk mencapai presisi tinggi yang diperlukan untuk dukungan klinis yang andal.

Oleh karena itu, dengan menyadari tantangan yang ada dan potensi arsitektur terbaru, penelitian ini bertujuan untuk mengisi celah spesifik dalam analisis jerawat otomatis. Sementara sistem komprehensif seperti ACNE8M menargetkan berbagai kondisi dermatologis, investigasi yang terfokus pada proses *fine-tuning* yang rumit untuk meningkatkan presisi pada tiga jenis jerawat yang secara visual mirip dan sering salah didiagnosis—yaitu komedo hitam, jerawat jamur, dan jerawat nodul—masih kurang dieksplorasi. Tujuan utama dari penelitian ini adalah untuk melakukan *fine-tuning* secara cermat pada model YOLOv8n yang efisien secara komputasi melalui eksplorasi iteratif terhadap parameter-parameter kunci, termasuk ukuran gambar, pelatihan *multi-scale*, dan strategi augmentasi data. Pemilihan varian 'n' (nano) dilakukan secara sengaja, dengan tujuan menghasilkan model yang tidak hanya presisi tetapi juga ringan, sehingga layak untuk implementasi praktis pada perangkat dengan sumber daya terbatas seperti ponsel. Tujuannya adalah untuk mengidentifikasi konfigurasi optimal yang secara signifikan meningkatkan keandalan dan presisi dalam membedakan subtipe spesifik ini, sehingga menawarkan landasan yang kuat untuk alat bantu diagnostik yang lebih cepat dan efisien. Alat semacam itu berpotensi mengurangi waktu diagnosis, mendukung konsultasi teledermatologi, dan menyediakan analisis awal yang dapat diakses oleh pasien, yang pada akhirnya memfasilitasi pengobatan yang lebih tepat waktu dan sesuai.

2. Studi Terkait

Berbagai metodologi telah diimplementasikan untuk deteksi jerawat otomatis. Penelitian yang memanfaatkan arsitektur YOLOv5, seperti studi oleh Pinasty dan Hakim, menunjukkan potensinya untuk deteksi jerawat multikelas—khususnya untuk komedo (*blackhead*), papula, pustula, nodul, dan komedo putih (*whiteheads*)—dengan melaporkan metrik kinerja keseluruhan yang tinggi [9]. Sebaliknya, investigasi lain yang juga menggunakan YOLOv5 oleh Sangha dan Rizvi menghasilkan mAP@0.5 yang jauh lebih rendah, yaitu 26.50%, ketika membedakan beberapa kelas jerawat. Hal ini menggarisbawahi adanya variabilitas dan tantangan dalam domain ini [1].

Melihat tantangan tersebut, evolusi berkelanjutan dari arsitektur YOLO menawarkan kemajuan yang signifikan. Iterasi terbaru, YOLOv8, memberikan peningkatan substansial dari pendahulunya dalam hal kecepatan dan akurasi [13]. Sebuah studi terkemuka yang mengembangkan sistem ACNE8M memanfaatkan kemampuan ini dan berhasil mendeteksi 12 kondisi terkait jerawat secara komprehensif, termasuk jerawat jamur (*Pityrosporum Folliculitis*), dengan menggunakan model besar YOLOv8l-seg dan mencapai mAP sebesar 0.69 [12]. Meskipun studi ACNE8M menunjukkan potensi diagnostik yang luas dari model YOLOv8 skala besar, penelitian kami menyajikan analisis yang komplementer dan lebih terperinci. Penelitian ini berfokus secara spesifik pada proses *fine-tuning* model yang ringan (YOLOv8n) untuk mengoptimalkan presisi deteksi pada sub-kelompok yang menantang, yaitu komedo hitam, jerawat jamur, dan jerawat nodul, sebuah kombinasi yang belum secara eksplisit dibahas dalam penelitian-penelitian sebelumnya.

Tinjauan literatur yang ada ini mengungkapkan bahwa meskipun telah tercapai kemajuan signifikan dalam deteksi objek berbasis *deep learning* untuk jerawat, masih terdapat kebutuhan krusial untuk peningkatan presisi dalam diferensiasi visual otomatis pada subtipe jerawat yang spesifik dan sering kali menantang, yaitu komedo hitam, jerawat jamur, dan jerawat nodul. Proses *fine-tuning* yang strategis pada arsitektur canggih seperti YOLOv8, khususnya varian efisien seperti YOLOv8n yang dieksplorasi dalam penelitian ini,

menyajikan sebuah jalur yang menjanjikan untuk mengatasi tantangan yang tersisa secara efektif dan meningkatkan keandalan sistem deteksi jerawat otomatis.

3. Metodologi Penelitian

3.1 YOLOv8

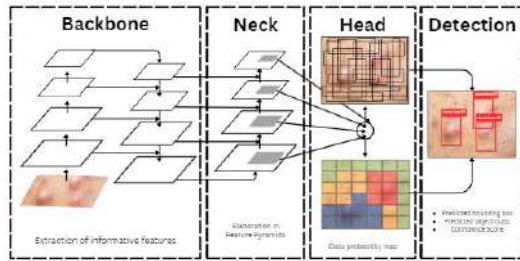
YOLOv8 merupakan kemajuan terbaru dalam seri model You Only Look Once (YOLO), yang dikembangkan oleh Ultralytics dan dirilis pada 10 Januari 2023 [14]. Model ini dibangun di atas keberhasilan para pendahulunya, termasuk YOLOv5, dengan menawarkan peningkatan signifikan dalam kecepatan, akurasi, dan efisiensi secara keseluruhan pada tugas deteksi objek [15], [16]. Hal ini membuat YOLOv8 sangat cocok untuk aplikasi yang menuntut seperti pencitraan medis, di mana deteksi yang presisi dan cepat sangat krusial [13].

Arsitektur YOLOv8, seperti versi YOLO sebelumnya, secara umum terdiri dari tiga bagian utama: *Backbone*, *Neck*, dan *Head*. *Backbone* berfungsi untuk mengekstraksi fitur-fitur penting dari gambar masukan, dengan memanfaatkan versi modifikasi dari arsitektur CSPDarknet53. *Neck* kemudian memproses fitur-fitur ini, sering kali menggunakan komponen seperti PANet (*Path Aggregation Network*) untuk menggabungkan informasi multi-skala, yang meningkatkan kemampuan model untuk mendeteksi objek dengan berbagai ukuran. *Neck* pada YOLOv8 secara langsung menggabungkan (*concatenate*) fitur tanpa memaksakan dimensi kanal yang seragam, yang berkontribusi pada pengurangan jumlah parameter dan ukuran tensor secara keseluruhan. Terakhir, *Head* membuat prediksi akhir, termasuk koordinat *Bounding box*, probabilitas kelas, dan skor kepercayaan (*confidence score*) untuk setiap objek yang terdeteksi [11], [14], [15], [17]. YOLOv8 memperkenalkan pendekatan *anchor-free* untuk prediksi *bounding box*, yang menyederhanakan proses prediksi dan mengurangi jumlah hiperparameter. Pendekatan ini juga meningkatkan kemampuan adaptasi model terhadap objek dengan berbagai rasio aspek dan skala [14].

YOLOv8 menawarkan beberapa model dengan berbagai ukuran dan kompleksitas, seperti nano (YOLOv8n), kecil (*small*/YOLOv8s), sedang (*medium*/YOLOv8m), besar (*large*/YOLOv8l), dan ekstra besar (*extra-large*/YOLOv8x). Hal ini memberikan fleksibilitas untuk berbagai sumber daya komputasi dan kebutuhan kinerja [14]. Untuk penelitian ini, varian YOLOv8n dipilih secara khusus karena keseimbangan optimalnya antara akurasi deteksi dan efisiensi komputasi, menjadikannya sesuai untuk potensi implementasi di mana sumber daya mungkin terbatas, sambil tetap memanfaatkan fitur arsitektur canggih dari seri YOLOv8 untuk diferensiasi lesi yang presisi. Kinerjanya yang lebih baik dibandingkan versi sebelumnya, termasuk YOLOv5, membuatnya lebih stabil dan efisien untuk deteksi objek kelas tunggal maupun multikelas, bahkan dengan dataset yang lebih kecil [11], [15]. Sebagai contoh, model YOLOv8x yang lebih besar mencapai *Average Precision* (AP) sebesar 53.9% dengan ukuran gambar 640 piksel, melampaui AP YOLOv5 sebesar 50.7% pada ukuran masukan yang sama [11]. Dalam konteks deteksi jerawat, kemampuan canggih dari arsitektur YOLOv8n yang dipilih diharapkan dapat meningkatkan diferensiasi jenis jerawat yang secara visual mirip, seperti komedo hitam, jerawat jamur, dan jerawat nodul, yang merupakan tantangan signifikan bagi model deteksi standar.

Kemajuan arsitektur lebih lanjut pada YOLOv8 mencakup penggantian lapisan C3 pada YOLOv5 dengan lapisan C2f yang baru. Lapisan C2f menggabungkan (*concatenate*) keluaran dari semua lapisan *Bottleneck*, tidak seperti lapisan C3 yang hanya memanfaatkan keluaran dari lapisan *Bottleneck* terakhir [15]. Modul C2f baru ini mengintegrasikan fitur tingkat tinggi dengan informasi kontekstual untuk meningkatkan akurasi deteksi [10], [15]. Penggunaan *mixed-precision training* memungkinkan YOLOv8 untuk memanfaatkan presisi *floating-point* 16-bit, yang secara signifikan mempercepat pelatihan pada GPU yang kompatibel sambil mempertahankan akurasi dan mengurangi konsumsi memori [14]. Seri YOLOv8 mencakup berbagai model yang dioptimalkan untuk tugas-tugas visi komputer spesifik, termasuk deteksi objek, segmentasi instans, deteksi pose/titik kunci, deteksi objek berorientasi, dan klasifikasi. Model-model ini kompatibel dengan berbagai mode operasional, seperti *Inference*, *Validation*, *Training*, dan *Export*, yang menyederhanakan penggunaannya selama proses implementasi dan pengembangan [14], [17].

Serupa dengan cara model mendeteksi objek pada gambar umum dengan melokalisasinya menggunakan *Bounding box* dan menetapkan probabilitas kelas, YOLOv8 dapat di-*fine-tune* untuk mengidentifikasi dan mengklasifikasikan berbagai jenis lesi jerawat, seperti komedo hitam, jerawat jamur, dan jerawat nodul. Kemampuan ini sangat krusial dalam bidang dermatologi untuk diagnosis yang lebih cepat dan akurat, seperti yang digambarkan pada Gambar 1.



Gambar 1. Implementasi deteksi jerawat pada YOLOv8

Integrasi ini menyoroti fleksibilitas YOLOv8 di luar pengenalan objek umum, menunjukkan potensinya untuk meningkatkan efisiensi dan akurasi diagnostik secara signifikan di bidang medis yang terspesialisasi.

3.2 Dataset

Pada penelitian ini, dataset disusun dengan menggabungkan gambar dari dua sumber yang tersedia untuk umum: Skin-90¹ dan DermNet², yang menghasilkan koleksi awal sebanyak 836 gambar mentah. Strategi agregasi ini bertujuan untuk menyediakan representasi yang beragam dari berbagai manifestasi jerawat. Selanjutnya, semua gambar menjalani proses anotasi manual yang terperinci menggunakan Roboflow³, sebuah platform khusus untuk persiapan dataset. Untuk membuat *ground truth*, anotasi dilakukan oleh penulis di bawah supervisi seorang ahli domain dengan mengikuti serangkaian pedoman yang telah ditentukan secara ketat untuk memastikan konsistensi. Untuk setiap lesi yang teridentifikasi, sebuah *Bounding box* yang rapat digambar untuk melingkupi area yang terlihat secara presisi. Label kelas yang sesuai—*blackhead*, *fungal acne*, atau *nodule*—kemudian ditetapkan berdasarkan karakteristik visual yang dijelaskan pada paragraf berikutnya. Label diekspor dalam format YOLOv8, yang menyediakan koordinat *Bounding box* yang dinormalisasi <class-ID> <x_center> <y_center> <width> <height> dan pengidentifikasi kelas untuk setiap objek yang terdeteksi. Dataset diorganisir ke dalam direktori standar latih (*train*), validasi (*validation*), dan uji (*test*), yang masing-masing berisi subdirektori untuk gambar dan label. Contoh ilustratif dari konten berkas anotasi disajikan pada Tabel I. Dataset dianotasi menjadi tiga kelas jerawat yang berbeda: komedo hitam (*blackhead*, ID kelas 0), jerawat jamur (*fungal acne*, ID kelas 1), dan jerawat nodul (*nodule*, ID kelas 2).

Tabel I. Contoh Konten File Anotasi YOLOv8

Class ID	x_center	y_center	width	height
0	0.18203125	0.15234375	0.0375	0.0484375
1	0.43125	0.48046875	0.8625	0.5609375
2	0.74921875	0.81328125	0.234375	0.21953125

Komedo hitam (*blackhead*) adalah komedo terbuka non-inflamasi yang muncul sebagai sumbatan folikel kecil dan gelap akibat oksidasi sebum dan debris seluler [6]. Jerawat jamur (*fungal acne* atau *Malassezia Folliculitis*), yang berbeda dari jerawat biasa, biasanya tampak sebagai papula dan pustula eritematosa berukuran seragam 2-4 mm, umum ditemukan di area seboroik seperti wajah (terutama dahi), dada, dan punggung, serta sering kali ditandai dengan sifatnya yang gatal (*pruritic*) [18]. Jerawat nodul merupakan bentuk jerawat inflamasi parah, yang bermanifestasi sebagai lesi berukuran lebih dari 5 mm, keras, dan sering kali nyeri yang berkembang lebih dalam di bawah kulit [6]. Gambar 2 mengilustrasikan contoh visual dari kelas-kelas ini yang diambil dari dataset.



Gambar 2. Contoh visual dari komedo hitam, jerawat jamur, dan jerawat nodul.

Untuk mengatasi tantangan umum kelangkaan data dalam pencitraan medis dan untuk meningkatkan robustisitas model, strategi augmentasi data yang komprehensif diterapkan, yang merupakan teknik kunci untuk meningkatkan generalisasi dari dataset yang terbatas [19]. Teknik pra-pemrosesan dan augmentasi data diterapkan untuk memperkaya dataset dan meningkatkan ketahanan model. Pra-pemrosesan meliputi *auto-orientation* dan pengubahan ukuran semua gambar ke resolusi seragam 640 x 640 piksel menggunakan metode

¹<https://www.kaggle.com/datasets/dinartas/skin90>

²<https://dermnetnz.org/>

³<https://roboflow.com/>

stretch. Augmentasi data kemudian dilakukan pada gambar latih, menghasilkan tiga versi augmentasi untuk setiap sampel latih asli. Teknik augmentasi yang digunakan meliputi pembalikan horizontal (*horizontal flipping*), pemotongan acak (*random cropping*, 0-15% zoom), rotasi ($\pm 10^\circ$), dan penyesuaian kecerahan ($\pm 15\%$). Prosedur ini memperbanyak total dataset menjadi 2008 gambar. Dataset hasil augmentasi ini kemudian dibagi menjadi himpunan data latih, validasi, dan uji, dengan alokasi 1758 gambar (88%) untuk pelatihan, 164 gambar (8%) untuk validasi, dan 86 gambar (4%) untuk pengujian. Pembagian ini memastikan kerangka kerja yang kuat untuk pelatihan model, penyesuaian hiperparameter, dan evaluasi akhir yang tidak bias.

3.3 Metrik Evaluasi

Untuk mengevaluasi kinerja model YOLOv8n yang telah di-*fine-tune*, digunakan metrik yang dirancang khusus untuk tugas deteksi objek. Berbeda dengan akurasi klasifikasi sederhana yang hanya mengukur kebenaran label tanpa mempertimbangkan lokalisasi, deteksi objek memerlukan metrik yang mengevaluasi baik klasifikasi maupun akurasi lokalisasi (*Bounding box*). Oleh karena itu, metrik utama yang digunakan dalam penelitian ini adalah *Precision*, *Recall*, dan *mean Average Precision* pada ambang batas *Intersection over Union* (IoU) 0.5 (mAP@0.5 atau mAP50).

Precision mengukur akurasi dari prediksi positif yang dibuat oleh model. Metrik ini didefinisikan sebagai rasio deteksi positif yang teridentifikasi dengan benar (*True Positives*, TP) terhadap jumlah total deteksi positif yang diprediksi oleh model (TP + *False positives*, FP) [20]. Nilai *Precision* yang tinggi menunjukkan bahwa model membuat sedikit kesalahan positif palsu. Rumus untuk *Precision* adalah:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Recall, yang juga dikenal sebagai sensitivitas, mengukur kemampuan model untuk mengidentifikasi semua instansi kelas yang relevan. Metrik ini dihitung sebagai rasio deteksi positif yang teridentifikasi dengan benar (TP) terhadap jumlah total instansi positif yang sebenarnya ada di dalam dataset (TP + *False Negatives*, FN) [20]. Nilai *Recall* yang tinggi menandakan bahwa model hanya melewatkan sedikit lesi yang sebenarnya ada. Rumus untuk *Recall* adalah:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Average Precision (AP) untuk setiap kelas dihitung sebagai luas area di bawah kurva *Precision-Recall* (PR). Kurva PR memplotkan nilai *Precision* terhadap *Recall* untuk berbagai ambang batas kepercayaan (*confidence threshold*) [21]. AP menyediakan sebuah nilai tunggal yang merangkum kinerja model untuk kelas tertentu. Rumus untuk AP secara umum direpresentasikan sebagai integral:

$$AP = \int_0^1 p(r) dr$$

di mana $p(r)$ adalah fungsi *Precision* terhadap *Recall* r .

Mean Average Precision (mAP) adalah rata-rata dari nilai-nilai AP untuk semua N kelas. Pada penelitian ini, mAP@0.5 (mAP50) digunakan, yang menandakan bahwa ambang batas IoU sebesar 0.5 diperlukan agar sebuah deteksi dianggap sebagai *True Positive*. Nilai mAP50 yang lebih tinggi umumnya menunjukkan model deteksi yang lebih akurat dan andal [20]. Rumus untuk mAP adalah:

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

Metrik-metrik ini dihitung untuk setiap kelas secara individual dan sebagai rata-rata keseluruhan di semua kelas pada himpunan data validasi (*validation set*) selama proses *fine-tuning* iteratif dan pada himpunan data uji (*test set*) untuk evaluasi model akhir.

4. Hasil dan Analisis

4.1 Proses *Fine-tuning* dan Temuan Kunci

Investigasi awal, Eksperimen 1, berfungsi sebagai *baseline* untuk menetapkan kinerja dasar dari model YOLOv8n. Eksperimen ini menggunakan konfigurasi standar, termasuk ukuran gambar masukan (*imgsz*) 640x640, *batch size* 16, dan augmentasi data ringan standar. Sebagaimana dirinci dalam Tabel II, konfigurasi *baseline* ini menghasilkan mAP50 keseluruhan sebesar 0.582 (*Precision*: 0.693, *Recall*: 0.513). Analisis per kelas menunjukkan deteksi awal yang memuaskan untuk jerawat jamur (*funggal acne*) (mAP50: 0.797) dan jerawat nodul (*acne nodule*) (mAP50: 0.582). Namun, komedo hitam (*blackhead*) (mAP50: 0.367) diidentifikasi sebagai kelas yang paling menantang, yang mengindikasikan perlunya representasi fitur yang lebih baik dan strategi augmentasi yang lebih kuat pada eksperimen-eksperimen berikutnya.

Berdasarkan observasi dari *baseline*, eksperimen kedua memperkenalkan peningkatan signifikan pada strategi augmentasi dan konfigurasi *loss*. Augmentasi HSV ($hsv_h=0.02$, $hsv_s=0.8$, $hsv_v=0.5$) dan

augmentasi geometris (*degrees*=10.0, *translate*=0.15, *scale*=0.6) diterapkan dengan intensitas yang ditingkatkan. Lebih lanjut, bobot *cls_loss* disesuaikan menjadi 0.75 untuk menekankan akurasi klasifikasi, dan *patience* untuk *early stopping* diatur ke 60. Konfigurasi ini, sambil mempertahankan *imgsz*=640 dan *batch_size*=16 tanpa pelatihan *multi_scale*, menghasilkan peningkatan yang signifikan pada kinerja keseluruhan, mencapai mAP50 keseluruhan tertinggi sebesar 0.594 (*Precision*:0.676, *Recall*:0.552), seperti yang ditunjukkan pada Tabel II. Kinerja mAP50 untuk *blackhead* meningkat menjadi 0.403, dan *fungus acne* mencapai puncak mAP50 sebesar 0.806. Hasil ini mengkonfirmasi efektivitas dari augmentasi yang lebih kaya dan penyesuaian bobot *loss*.

Selanjutnya, eksperimen ketiga bertujuan untuk mengeksplorasi dampak dari pelatihan *multi_scale* dengan mengaktifkan parameter *multi_scale*=*True* sambil mempertahankan *imgsz*=640 dan pengaturan augmentasi agresif (*degrees*=10.0, *translate*=0.15, *scale*=0.6) dari eksperimen sebelumnya. Pengalihan pelatihan *multi_scale* menyebabkan peningkatan mAP50 untuk *blackhead* menjadi 0.423 dan perbaikan substansial untuk *acne nodule*, yang mencapai puncak mAP50 sebesar 0.624. Namun, degradasi kinerja yang signifikan teramati pada *fungus acne*, dengan mAP50-nya menurun menjadi 0.692. Akibatnya, mAP50 keseluruhan sedikit menurun menjadi 0.580. Hasil ini menyoroti potensi pelatihan *multi_scale* untuk kelas-kelas dengan variasi ukuran tetapi juga mengungkapkan sensitivitas kritis *fungus acne* terhadap kombinasi masukan *multi_scale* dan augmentasi geometris yang agresif.

Eksperimen keempat dilakukan untuk mengatasi penurunan kinerja pada *fungus acne* yang teramati sebelumnya dengan *multi_scale*=*True* dan augmentasi agresif. Sambil mempertahankan *imgsz*=640, *multi_scale*=*True*, *batch_size*=16, dan *cls_loss*=0.75, intensitas augmentasi geometris dikurangi (*degrees*=5.0, *translate*=0.1, *scale*=0.5). Penyesuaian ini menghasilkan pemulihan kinerja *fungus acne* yang signifikan, mencapai mAP50 sebesar 0.764. Deteksi *blackhead* (0.411) dan *nodule* (0.587) tetap kuat. Perlu dicatat, konfigurasi ini menghasilkan *Recall* keseluruhan tertinggi (0.572) dengan mAP50 keseluruhan 0.587, yang menunjukkan model yang seimbang di semua kelas, meskipun dengan *Precision* yang relatif lebih rendah yaitu 0.596.

Untuk memaksimalkan deteksi *blackhead*, eksperimen kelima menggunakan *imgsz*=800 dengan *multi_scale*=*True*. Karena keterbatasan VRAM, *batch_size* dikurangi menjadi 8. Augmentasi geometris yang agresif (*degrees*=10.0, *translate*=0.15, *scale*=0.6) dan *cls_loss*=0.75 digunakan, dengan *learning rate* yang ditentukan secara otomatis (sekitar 0.001429). Konfigurasi ini menghasilkan mAP50 puncak absolut untuk *blackhead* (0.446) dan *Precision* keseluruhan tertinggi (0.691) yang teramati hingga saat itu. Namun, hal ini dicapai dengan konsekuensi penurunan kinerja yang signifikan untuk *fungus acne* (0.687) dan *acne nodule* (0.538), yang menghasilkan mAP50 keseluruhan yang lebih rendah yaitu 0.557. Eksperimen ini menggarisbawahi adanya *trade-off* yang nyata ketika melakukan optimisasi untuk satu kelas yang menantang.

Iterasi terakhir, eksperimen keenam, bertujuan untuk mencapai presisi tinggi sambil menjaga keseimbangan yang baik, dengan kembali menggunakan *imgsz*=640 dengan *multi_scale*=*True* dan *batch_size*=16. Augmentasi geometris dicampur: *degrees* (10.0) dan *translate* (0.15) tetap agresif, sementara *scale* diatur ke nilai yang lebih ringan yaitu 0.5. Konfigurasi ini menghasilkan mAP50 keseluruhan sebesar 0.589 (tertinggi kedua) dan, yang terpenting untuk fokus penelitian ini, *Precision* keseluruhan tertinggi (0.693). Deteksi *blackhead* sangat baik (mAP50: 0.442, terbaik untuk *imgsz*=640), kinerja *fungus acne* pulih dengan baik (mAP50: 0.750), dan deteksi *nodule* solid (mAP50: 0.576). Hal ini menunjukkan bahwa penyesuaian parameter augmentasi yang cermat, terutama faktor *scale* yang dikombinasikan dengan pelatihan *multi_scale*, dapat menghasilkan presisi yang unggul sambil mempertahankan kemampuan deteksi keseluruhan yang kuat.

Tabel II. Ringkasan Eksperimen Fine-Tuning Iteratif YOLOv8n: Parameter dan Metrik Kinerja. Nilai keseluruhan terbaik dan puncak kunci per kelas ditandai dengan cetak tebal.

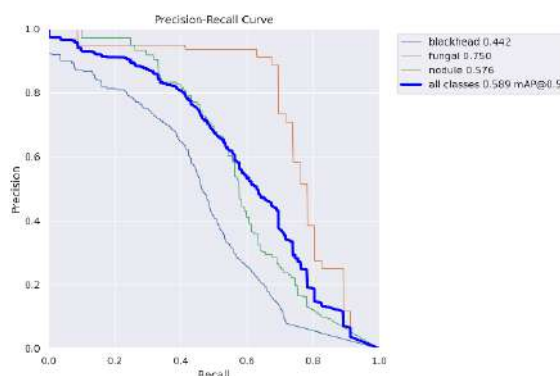
Exp.	imgsz	MS	Scale	Deg.	Transl.	Batch	cls	LR	Time (h)	mAP ^{50all}	P _{all}	R _{all}	BH ₅₀	FU ₅₀	NO ₅₀
1	640	No	0.5	0.0	0.1	16	0.50	Auto	0.505	0.582	0.693	0.513	0.367	0.797	0.582
2	640	No	0.6	10.0	0.15	16	0.75	Auto	0.715	0.594	0.676	0.552	0.403	0.806	0.573
3	640	Yes	0.6	10.0	0.15	16	0.75	Auto	0.894	0.580	0.658	0.533	0.423	0.692	0.624
4	640	Yes	0.5	5.0	0.1	16	0.75	Auto	0.813	0.587	0.596	0.572	0.411	0.764	0.587
5	800	Yes	0.6	10.0	0.15	8	0.75	Auto	1.352	0.557	0.691	0.552	0.446	0.687	0.538
6	640	Yes	0.5	10.0	0.15	16	0.75	Auto	0.959	0.589	0.693	0.532	0.442	0.750	0.576

Notes: **Exp.**: Eksperimen. **MS**: Pelatihan Multi-Scale. **Deg.**: Derajat (*Degrees*), **Transl.**: Translasi (*Translate*). **cls**: Bobot *loss* klasifikasi. **LR**: *Learning rate* efektif (Otomatis ≈ 0.001429 untuk *batch* 16, dapat bervariasi untuk *batch* 8). **Waktu**: Waktu pelatihan dalam jam. **P**: *Precision*. **R**: *Recall*. **BH**: Komedo Hitam (*Blackhead*). **FU**: Jerawat Jamur (*Fungal Acne*). **NO**: Nodul Jerawat (*Acne Nodules*). Subskrip 50 menandakan mAP pada IoU 0.50.

4.2 Analisis Kurva *Precision-recall*

Kurva *precision-recall* (PR) dari Eksperimen 6 dianalisis untuk mengevaluasi lebih lanjut kinerja deteksi model, terutama *trade-off* antara *precision* dan *recall*. Gambar 3 menyajikan kurva PR untuk setiap kelas (*blackhead*, *fungus acne*, *acne nodule*) dan *mean Average Precision* (mAP) pada ambang batas IoU 0.5.

Gambar 3 menunjukkan bahwa kelas *fungal acne* menampilkan kurva PR yang paling mendekati sudut kanan atas yang ideal, dengan mencapai *Average Precision* (AP) sebesar 0.750. Hal ini mengindikasikan kinerja yang kuat dan seimbang antara *precision* dan *recall* untuk kelas ini. Kelas *acne nodule* juga menunjukkan kinerja yang baik dengan AP sebesar 0.576; kurvanya tetap relatif stabil pada tingkat *precision* yang tinggi sebelum menurun pada nilai *recall* yang lebih tinggi.




Gambar 3. Kurva PR dari eksperimen 6.

Untuk kelas *blackhead*, kurva PR menghasilkan AP sebesar 0.442. Meskipun nilai AP ini lebih rendah dibandingkan dua kelas lainnya, bentuk kurva menunjukkan bahwa model masih dapat mencapai *precision* yang wajar pada berbagai tingkat *recall* untuk instansi-instansi yang menantang ini, yang biasanya berukuran kecil dan berjumlah banyak. Penurunan *precision* yang lebih cepat seiring dengan meningkatnya *recall* untuk *blackhead* merupakan karakteristik dari kategori objek semacam itu.

Kurva PR rata-rata (mAP@0.5) mencapai 0.589, yang menggambarkan kinerja model keseluruhan yang solid. Kurva PR untuk Eksperimen 6 menguatkan temuan kuantitatif, mengonfirmasi kemampuan model untuk mencapai tingkat *precision* yang tinggi (*Precision* keseluruhan: 0.693). *Precision* yang kuat ini menggarisbawahi kesesuaian model untuk tugas 'Deteksi Presisi' (*Precision Detection*), di mana identifikasi lesi jerawat yang akurat sangat penting.

Untuk mendukung secara visual kinerja dan presisi model YOLOv8n yang telah dioptimalkan dari Eksperimen 6, Gambar 4 menyajikan contoh-contoh deteksi yang representatif pada gambar uji. Gambar-gambar ini menunjukkan kemampuan model dalam mengidentifikasi setiap kelas jerawat target: *blackhead*, *fungal acne*, dan *acne nodule*. Model ini dipilih untuk tinjauan kualitatif karena pencapaian *precision* keseluruhan tertinggi (P_{all} : 0.693).



Gambar 4. Contoh visual deteksi presisi dari eksperimen 6 pada data uji, yang menunjukkan kinerja pada (a) komedo hitam (*blackhead*), (b) jerawat jamur (*fungal acne*), dan (c) jerawat nodul (*acne nodule*).

Gambar 4a mengilustrasikan kinerja model dalam mendeteksi lesi *blackhead*. Model menunjukkan kemampuan yang patut dipuji dalam mengidentifikasi banyak instansi *blackhead*, termasuk yang tampak samar atau redup. *Bounding box* umumnya ditempatkan dengan baik, bahkan untuk deteksi dengan skor kepercayaan (*confidence score*) yang bervariasi dalam rentang 0.3 hingga 0.6. Namun, gambar tersebut juga mengungkapkan adanya *false positives*, di mana fitur non-komedo atau variasi tekstur kulit terdeteksi secara keliru sebagai lesi *blackhead*. Meskipun deteksi yang benar terhadap lesi-lesi samar ini patut diperhatikan, keberadaan *false positives* berkontribusi pada mAP50 keseluruhan sebesar 0.442 untuk kelas ini (Tabel II). Walaupun merupakan yang terbaik untuk konfigurasi *imgsz=640* dengan *multi_scale=True*, skor ini mencerminkan tantangan yang melekat pada deteksi *blackhead* karena ukuran objek yang kecil, varians intra-kelas yang tinggi, dan potensi kebingungan dengan fitur kulit lainnya, sehingga menawarkan ruang untuk penyempurnaan lebih lanjut dalam hal spesifisitas.

Selanjutnya, Gambar 4b menunjukkan keberhasilan deteksi model terhadap *funggal acne*. Model secara efektif melokalisasi dan membatasi area yang terdampak di dahi, menampilkan lesi yang khas dan sering kali bergerombol yang terkait dengan *funggal acne*. Hasil kualitatif ini selaras dengan mAP50 yang kuat sebesar 0.750 untuk kelas ini, yang menunjukkan kemahiran model dalam mengenali pola visualnya yang khas.

Gambar 4c menyajikan contoh representatif dari keberhasilan deteksi *acne nodule*. Model mengidentifikasi dan membatasi lesi nodul yang jelas secara akurat. Kinerja ini konsisten dengan mAP50 sebesar 0.576 untuk nodul, yang menggambarkan kemampuan model untuk menangani jenis lesi yang lebih menonjol dan sering kali terletak lebih dalam ini.

Contoh-contoh kualitatif pada Gambar 4 ini secara kolektif memperkuat metrik kuantitatif yang disajikan pada Tabel II. Model dari Eksperimen 6 menunjukkan kemampuan yang kuat untuk mengidentifikasi ketiga jenis lesi jerawat. *Precision* keseluruhan yang tinggi (0.693) didukung oleh lokalisasi yang secara umum akurat, meskipun analisis deteksi *blackhead* menyoroti bahwa bahkan dengan contoh visual yang baik, tantangan untuk meminimalkan *false positives* tetap relevan untuk mencapai skor mAP yang lebih tinggi pada kelas-kelas yang kompleks. Wawasan visual ini menggarisbawahi potensi model sebagai alat yang efektif untuk identifikasi lesi jerawat yang presisi.

4.3 Analisis Kompleksitas Komputasi

Selain akurasi deteksi, kompleksitas komputasi dari model-model yang telah di-*fine-tune* juga dievaluasi untuk menilai kepraktisannya dalam implementasi di dunia nyata. Analisis ini berfokus pada durasi pelatihan dan kecepatan *inference*, yang merupakan faktor-faktor krusial untuk pengembangan dan aplikasi model.

Waktu pelatihan untuk setiap eksperimen dirinci dalam Tabel II. Sebuah tren yang jelas teramati, di mana konfigurasi dengan ukuran gambar masukan yang lebih besar (*imgsz*=800) dan *batch size* yang lebih kecil (contohnya, Eksperimen 5) memerlukan durasi pelatihan yang jauh lebih lama (1.352 jam) dibandingkan dengan konfigurasi yang menggunakan *imgsz*=640 dan *batch size* yang lebih besar. Sebagai contoh, model *baseline* (Eksperimen 1) selesai dalam waktu sekitar 0.5 jam. Hal ini menyoroti adanya *trade-off* komputasi yang terkait dengan pelatihan pada gambar beresolusi lebih tinggi.

Untuk mengevaluasi efisiensi implementasi, kecepatan *inference* dari model dengan kinerja terbaik (dari Eksperimen 6) diukur pada GPU NVIDIA GeForce RTX 4060. Kinerjanya dirangkum dalam Tabel III. Model ini mencapai total waktu pemrosesan 10.9 milidetik per gambar, dengan langkah *inference* inti hanya memakan waktu 5.3 ms. Kecepatan pemrosesan yang tinggi ini menunjukkan kesesuaian model untuk aplikasi *real-time* atau mendekati *real-time*, seperti pada alat bantu diagnostik berbasis seluler.

Tabel III. Kecepatan Inferensi Model Yang Dioptimalkan (Eksperimen 6)

Metrik	Waktu per Citra (ms)
Pra-pemrosesan	0.4
Inferensi	5.3
Pasca-pemrosesan	5.2
Total	10.9

Perlu dicatat pula bahwa, karena semua eksperimen menggunakan arsitektur YOLOv8n, ukuran model tetap konsisten sekitar 3.0 juta parameter, dengan beban komputasi sebesar 8.1 GFLOPs untuk gambar masukan berukuran 640x640. Analisis ini mengonfirmasi bahwa metodologi *fine-tuning* yang diusulkan tidak hanya meningkatkan presisi deteksi tetapi juga mempertahankan efisiensi komputasi tinggi yang menjadi ciri khas model YOLOv8 nano, menjadikannya solusi yang layak dan praktis.

4.4 Diskusi

Proses *fine-tuning* mencapai puncaknya pada Eksperimen 6, yang menghasilkan model YOLOv8n teroptimisasi dengan *precision* keseluruhan yang tinggi sebesar 0.693 dan mAP50 yang kuat sebesar 0.589. Ketika dikontekstualisasikan dengan penelitian terkait, hasil ini merepresentasikan sebuah kemajuan yang terfokus pada deteksi jerawat yang berorientasi pada presisi. Sebagai contoh, mAP50 multikelas model penelitian ini sebesar 0.589 secara signifikan melampaui angka 26.50% yang dilaporkan oleh Sangha dan Rizvi [1] untuk tugas multikelas serupa menggunakan YOLOv5. Meskipun penelitian oleh Pinasty dan Hakim [9] juga mencapai metrik yang tinggi dengan YOLOv5, penelitian ini menunjukkan keberhasilan penerapan arsitektur YOLOv8n yang lebih baru pada tiga jenis jerawat menantang yang mencakup *funggal acne*, sebuah sub tipe yang secara klinis berbeda dan tidak dibahas dalam studi mereka. Dibandingkan dengan sistem komprehensif ACNE8M [12], yang mencapai mAP lebih tinggi yaitu 0.69 dengan model besar YOLOv8l-seg, penelitian ini menawarkan kontribusi komplementer dengan menunjukkan bahwa model ringan yang efisien secara komputasi dapat dioptimalkan secara spesifik untuk presisi tinggi pada sub-kelompok lesi yang ambigu secara visual. Fokus pada presisi dengan model yang efisien ini sangat krusial untuk implementasi praktis pada alat bantu klinis *real-time* atau berbasis seluler. Terakhir, tantangan yang terus-menerus ada dalam mendeteksi objek kecil, seperti *blackhead* (mAP50: 0.442), sejalan dengan temuan dari studi seperti yang dilakukan oleh Huang et al. [22], yang menyarankan arah yang jelas untuk penyempurnaan di masa depan pada teknik deteksi objek kecil.

5. Kesimpulan

Kontribusi utama dari penelitian ini terletak pada proses *fine-tuning* yang sistematis dan iteratif pada model YOLOv8n untuk deteksi presisi pada tiga sub tipe jerawat yang menantang secara visual: komedo hitam (*blackhead*), jerawat jamur (*fungus acne*), dan nodul (*acne nodule*). Studi ini menunjukkan bahwa melalui penyesuaian metodis pada hiperparameter kunci, sebuah model yang ringan dan efisien dapat dioptimalkan untuk tugas-tugas berpresisi tinggi. Eksperimen 6, yang menggunakan $imgsz=640$, pelatihan *multi-scale*, dan augmentasi geometris campuran yang disesuaikan, diidentifikasi sebagai konfigurasi optimal. Model ini mencapai *precision* keseluruhan tertinggi (P_{all} : 0.693) dan mAP50 keseluruhan yang kuat sebesar 0.589, dengan skor per kelas yang solid untuk *blackhead* (0.442), *fungus acne* (0.750), dan *acne nodule* (0.576). Temuan kuncinya adalah bahwa keseimbangan yang cermat pada parameter augmentasi, terutama faktor scale yang dikombinasikan dengan pelatihan *multi-scale*, sangat penting untuk meningkatkan presisi sambil mempertahankan kinerja yang kuat di semua kelas. Hasil ini menyediakan metodologi *fine-tuning* yang berharga dan menawarkan landasan yang kuat untuk mengembangkan alat bantu diagnosis berbantuan komputer yang lebih andal di bidang dermatologi. Untuk mendukung reproduktifitas dan mendorong inovasi lebih lanjut di bidang ini, kode sumber dan bobot model akhir yang terkait dengan studi ini telah disediakan untuk publik di GitHub⁴.

Meskipun hasil ini menjanjikan, penelitian ini mengakui beberapa keterbatasan, termasuk cakupan dataset yang bersumber dari publik dan tantangan dalam mendeteksi lesi kecil, seperti *blackhead* (mAP50 sebesar 0.442), di mana beberapa *false positive* teramati. Penelitian di masa depan sebaiknya memprioritaskan perluasan dataset pelatihan dengan gambar yang beragam dan tervalidasi secara klinis untuk meningkatkan robustisitas dan kemampuan generalisasi model. Investigasi lebih lanjut juga dapat mengeksplorasi varian YOLOv8 yang lebih besar, arsitektur alternatif, dan teknik-teknik canggih untuk secara spesifik meminimalkan *false positive*, yang pada akhirnya membuka jalan bagi alat diagnostik yang lebih komprehensif dan andal untuk implementasi klinis.

Daftar Pustaka

- [1] A. Sangha and M. Rizvi, "Detection of acne by deep learning object detection," *medRxiv*, p. 2021.12.05.21267310, Jan. 2021, doi: 10.1101/2021.12.05.21267310.
- [2] Q. T. Huynh *et al.*, "Automatic Acne Object Detection and Acne Severity Grading Using Smartphone Images and Artificial Intelligence," *Diagnostics*, vol. 12, no. 8, Aug. 2022, doi: 10.3390/diagnostics12081879.
- [3] R. V. Reynolds *et al.*, "Guidelines of care for the management of acne vulgaris," *J Am Acad Dermatol*, vol. 90, no. 5, pp. 1006.e1-1006.e30, May 2024, doi: 10.1016/j.jaad.2023.12.017.
- [4] F. V. Hendryanna, Y. W. Syaifudin, M. A. Hendrawan, N. Funabiki, and I. Siradjuddin, "Recognizing acne Vulgaris severity levels: An application of faster R-CNN and YOLO methods on medical images," in *AIP Conference Proceedings*, American Institute of Physics, Jul. 2024. doi: 10.1063/5.0201131.
- [5] E. Maligna and M.-A. Kurochkina, "Development of the Mobile Application for Assessing Facial Acne Severity from Photos," in *2021 IEEE Conference of Russian Young Researchers in Electrical and Electronic Engineering (ElConRus)*, 2021, pp. 1790–1793. doi: 10.1109/ElConRus51938.2021.9396382.
- [6] M. Vasam, S. Korutla, and R. A. Bohara, "Acne vulgaris: A review of the pathophysiology, treatment, and recent nanotechnology based advances," *Biochem Biophys Rep*, vol. 36, p. 101578, 2023, doi: <https://doi.org/10.1016/j.bbrep.2023.101578>.
- [7] N. Hazarika and M. Archana, "The psychosocial impact of acne vulgaris," *Indian J Dermatol*, vol. 61, no. 5, pp. 515–520, Sep. 2016, doi: 10.4103/0019-5154.190102.
- [8] B. Dréno, "What is new in the pathophysiology of acne, an overview," *Journal of the European Academy of Dermatology and Venereology*, vol. 31, no. S5, pp. 8–12, Sep. 2017, doi: <https://doi.org/10.1111/jdv.14374>.
- [9] S. Pinasty, R. Bagus, and F. Hakim, "Automatic Detection of Acne Types Using The YOLOv5 Method," *Indonesian Journal of Artificial Intelligence and Data Mining (IJAIMD)*, vol. 8, no. 1, pp. 236–248, 2025, doi: 10.24014/ijaidm.v8i1.35617.
- [10] J. Terven and D. Cordova-Esparza, "A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS," Feb. 2024, doi: 10.3390/make5040083.
- [11] M. A. R. Alif and M. Hussain, "YOLOv1 to YOLOv10: A comprehensive review of YOLO variants and their application in the agricultural domain," Jun. 2024, [Online]. Available: <http://arxiv.org/abs/2406.10139>
- [12] P. K. Nguyen, T. D. Le, B. A. Nguyen, and P. A. Nguyen, "ACNE8M - An acnes detection and differential

⁴<https://github.com/eursamajor/Fine-Tuning-YOLOv8n>

- diagnosis system using AI technologies,” *Science & Technology Development Journal*, 2024, doi: 10.32508/stdj.v27i3.4293.
- [13] A. Widayani, A. M. Putra, A. R. Maghrieibi, D. Z. C. Adi, and Moh. H. F. Ridho, “Review of Application YOLOv8 in Medical Imaging,” *Indonesian Applied Physics Letters*, vol. 5, no. 1, pp. 23–33, May 2024, doi: 10.20473/iapl.v5i1.57001.
 - [14] M. Yaseen, “What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector,” Aug. 2024, [Online]. Available: <http://arxiv.org/abs/2408.15857>
 - [15] M. Sohan, T. Sai Ram, and Ch. V. Rami Reddy, “A Review on YOLOv8 and Its Advancements,” 2024, pp. 529–545. doi: 10.1007/978-981-99-7962-2_39.
 - [16] R. Varghese and S. M., “YOLOv8: A Novel Object Detection Algorithm with Enhanced Performance and Robustness,” in *2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS)*, 2024, pp. 1–6. doi: 10.1109/ADICS58448.2024.10533619.
 - [17] P. Hidayatullah, N. Syakrani, M. R. Sholahuddin, T. Gelar, and R. Tubagus, “YOLOv8 to YOLO11: A Comprehensive Architecture In-depth Comparative Review,” *CoRR*, vol. abs/2501.13400, 2025, doi: 10.48550/ARXIV.2501.13400.
 - [18] M. A. S. Henning *et al.*, “Position statement: Recommendations on the diagnosis and treatment of Malassezia folliculitis,” *Journal of the European Academy of Dermatology and Venereology*, vol. 37, no. 7, pp. 1268–1275, Jul. 2023, doi: 10.1111/jdv.18982.
 - [19] L. Alzubaidi *et al.*, “A survey on deep learning tools dealing with data scarcity: definitions, challenges, solutions, tips, and applications,” *J Big Data*, vol. 10, no. 1, p. 46, 2023, doi: 10.1186/s40537-023-00727-2.
 - [20] A. Tharwat, “Classification assessment methods,” *Applied Computing and Informatics*, vol. 17, no. 1, pp. 168–192, 2018, doi: 10.1016/j.aci.2018.08.003.
 - [21] R. Padilla, S. L. Netto, and E. A. B. da Silva, “A Survey on Performance Metrics for Object-Detection Algorithms,” in *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*, 2020, pp. 237–242. doi: 10.1109/IWSSIP48289.2020.9145130.
 - [22] H. Huang, B. Wang, J. Xiao, and T. Zhu, “Improved small-object detection using YOLOv8: A comparative study,” *Applied and Computational Engineering*, vol. 41, no. 1, pp. 80–88, Feb. 2024, doi: 10.54254/2755-2721/41/20230714.